ANALISIS DESCRIPTIVOS Y PATRONES DE TENDENCIA

JUAN PABLO MULETT VERGARA

ANALISIS ESTADISTICO DE INFORMACION

UCOMPENSAR

2026

INTRODUCCION.

En este informe se desarrolla un análisis estadístico descriptivo sobre un conjunto de transacciones de venta, con el fin de aplicar los conceptos de clasificación de variables, organización de datos, medidas de tendencia central, dispersión, y detección de datos atípicos. Los datos que use provienen de un dataset de la plataforma Kaggle y corresponden a un registro sintético de ventas del periodo 2022 – 2025. El procesamiento y los gráficos fueron realizados en Python.

El trabajo se organiza en cinco partes. Primero se plantea el problema y se justifica su relevancia. Segundo, se describen las seis variables seleccionadas y el proceso de limpieza aplicado a la base. Tercero, se realiza el análisis univariado de cada variable mediante tablas de frecuencia y gráficos. Cuarto, se estudia la relación entre dos variables cualitativas y entre dos cuantitativas. Por último, se calculan e interpretan las medidas descriptivas.

PLANTEAMIENTO DEL PROBLEMA.

En el entorno comercial actual, las empresas venden a través de múltiples canales, y comprender cuales son los que generan mayores ingresos y utilidades es clave para asignar recursos y definir las estrategias de mercado. La transición del comercio multicanal al omnicanal ha hecho que los canales físicos y digitales convivan y compitan por el mismo cliente, por lo que medir su desempeño relativo resulta indispensable para la toma de decisiones. A su vez, la estadística descriptiva permite resumir grandes volúmenes de transacciones mediante tablas de frecuencia, medidas de tendencia central y de dispersión, y detectar datos atípicos que distorsionan los prromedios (Devore, 2021; Triola, 2004). En este trabajo se analizan 17.830 transacciones de ventas, ya depuradas, de un conjunto de datos sintético publicado en Kaggle, que abarca el periodo 2022 – 2025 y registra el canal de venta, la categoría del producto, la cantidad, los días de entrega, el monto vendido y la utilidad. Al ser datos simulados con fines educativos, los resultados describen el comportamiento del conjunto de datos, y no el de un mercado real. Se busca identificar donde se concentran las ventas y la utilidad, y si el monto vendido explica el comportamiento de la rentabilidad, considerando que ambas variables presentan alta variabilidad y valores extremos. Con base en lo anterior, se plantea la siguiente pregunta: ¿qué canales de venta y categorías de producto generan mayores ventas y utilidad, y que tan fuerte es la relación entre el monto vendido y la utilidad?

VARIABLES Y LIMPIEZA DE DATOS.

Descripción de la base de datos y selección de variables.

La base de datos utilizada corresponde a un registro sintético de transacciones de venta del periodo 2020 – 2025, obtenido en la plataforma Kaggle. En la versión original contiene 18.045 registros y 36 variables que describen al cliente, el producto, la ubicación, el precio, el pago y el resultado financiero de cada transacción, y viene acompañada de un diccionario de datos que define cada campo. Al tratar se datos simulados con fines educativos, los hallazgos que menciono en este informe describen el comportamiento de la base y no el de un mercado real.

Para responder la pregunta problema se seleccionaron seis variables. El canal de venta (Sales_Channel) y la categoría de producto (Product_Category) permiten identificar donde y que se vende. La cantidad de unidades (Quantity) y los días de entrega (Delivery_Days) describen el tamaño de cada compra y el nivel de servicio. El monto de la venta (Sales_Amount) y la utilidad (Profit) miden el resultado económico y permiten evaluar la relación entre ambas. En la Tabla 1 se presentan su definición, tipo y escala de medición.

Tabla 1 Cuadro de operacionalización de las variables

Variable	Definición	Tipo	Escala	Valores
Sales_Channel	Canal por el que se realizó la venta	Cualitativa	Nominal	Online, Retail, Store, B2B, Portal, Phone order
Product_Category	Categoría general del producto vendido	Cualitativa	Nominal	Electronics, Office Supplies, Furniture, Appliaces
Quantity	Unidades vendidas en la transacción	Cuantitativa discreta	Razón	1 a 11 unidades
Delivery_Days	Días transcurridos hasta la entrega	Cuantitativa discreta	Razón	0 a 10 días
Sales_Amount	Monto neto de la venta registrada	Cuantitativa discreta	Razón	16,68 a 14.303,07 unidades monetarias

Profit	Utilidad registrada de la transacción	Cuantitativa discreta	Razón	-299,31 a 3.512,08 unidades monetarias

Fuente: Elaboración Propia

Limpieza de datos.

Antes del análisis se depuro la base para corregir duplicados, inconsistencias y valores no válidos, como se resume en la Tabla 2. Se eliminaron 45 registros duplicados, 8 transacciones con cantidad menor o igual a cero y 162 registros sin dato de días de entrega. Las demás variables seleccionadas no presentaban valores faltantes. De esta forma se pasó de 18.045 a 17.830 registros, es decir, se conservo el 98,8% de la base original.

Tabla 2 Proceso de limpieza de datos

Paso	Problema	Acción	Registros resultantes
Base original			18.045
Duplicados	45 registros repetidos	Eliminados	18.000
Cantidades invalidas	8 transacciones con cantidad menor o igual a cero	Eliminadas	17.992
Valores faltantes	162 nulos en Delivery_Days	Eliminados	17.830
Base final	6 variables		17.830

Fuente: Elaboración propia

Además, se corrigieron inconsistencias de escritura en la categoría de producto: en la base original aparecían variantes de mayúsculas como “electronics”, “FURNITURE” y “Office supplies”, que se unificaron en Electronics, Furniture y Office Supplies. El canal de venta no presento inconsistencias. También se verifico la coherencia de la utilidad, comprobando que fuera igual a la venta menos el costo registrado. Las diferencias encontradas fueron en su mayoría de redondeo (alrededor de 0,01) y las superiores a una unidad monetaria representaron menos del 1% de los registros, por lo que se conservaron. Finalmente, los valores extremos de ventas y utilidad no se eliminaron, ya que reflejan transacciones reales dentro de la base y su análisis es parte del objetivo del estudio; se identifican mas adelante con el criterio del rango intercuartílico.

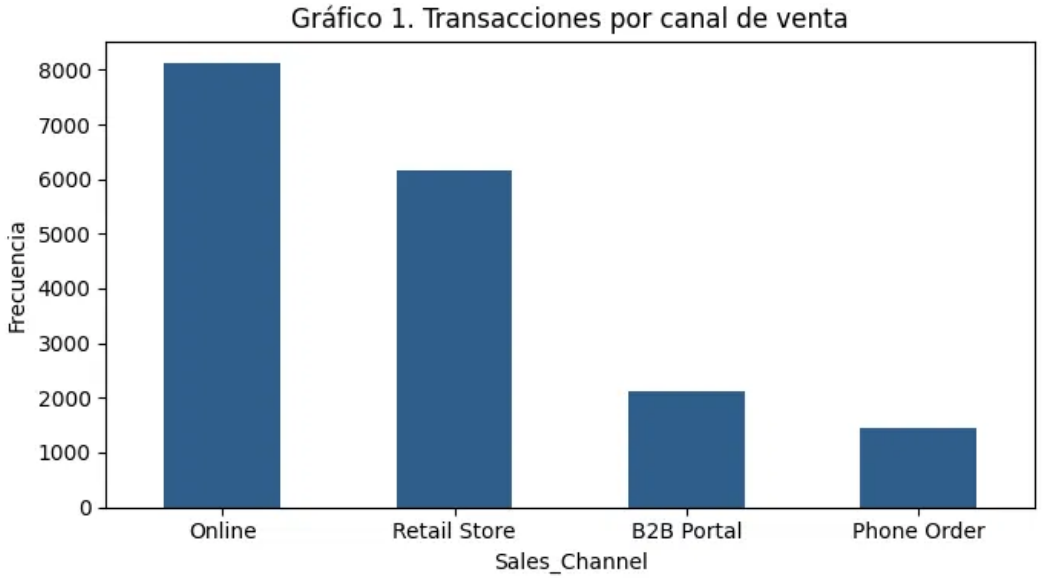
ANALISIS UNIVARIADO.

Variables cualitativas.

Tabla 3 Distribución de frecuencias del canal de venta

Canal de venta	Frecuencia absoluta	Frecuencia relativa	Porcentaje (%)	Frecuencia acumulada	Porcentaje acumulado (%)
Online	8.115	0,4551	45,51	8.115	45,51
Retail Store	6.168	0,3459	34,59	14.283	80,11
B2B Portal	2.111	0,1184	11,84	16.394	91,95
Phone Order	1.436	0,0805	8,05	17.830	100,00
Total	17.830	1,0000	100,00		

Fuente: Elaboración propia



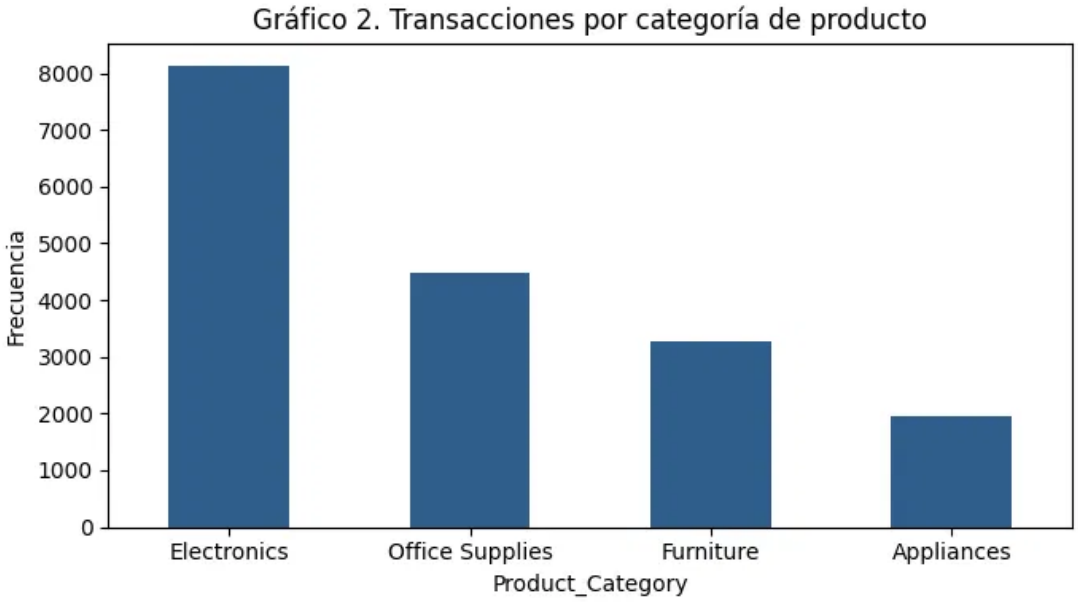
Fuente: Elaboración propia

La Tabla 3 y el Grafico 1 muestran que las ventas se concentran en dos canales. Online agrupa el 45,51% de las transacciones (8.115) y Retail Store el 34,59% (6.168), por lo que entre ambos reúnen el 80,11% del total. B2B Portal aporta el 11,84% y Phone Order, el canal con menor participación, el 8,05%. En el grafico, la barra de Online supera a la de retail Store por unas 2.000 transacciones, y las dos restantes quedan muy por debajo. Esto nos indica que la operación depende sobre todo de un canal digital y uno físico, mientras que los canales de contacto directo tienen un peso menor en cuanto a numero de ventas.

Tabla 4 Distribución de frecuencias de la categoría de producto

Categoría	Frecuencia absoluta	Frecuencia relativa	Porcentaje (%)	Frecuencia acumulada	Porcentaje acumulado (%)
Elotronics	8.120	0,4554	45,54	8.120	45,54
Office Supplies	4.469	0,2506	25,06	12.589	70,61
Furniture	3.275	0,1837	18,37	15.864	88,97
Appliances	1.966	0,1103	11,03	17.830	100,00
Total	17.830	1,0000	100,00		

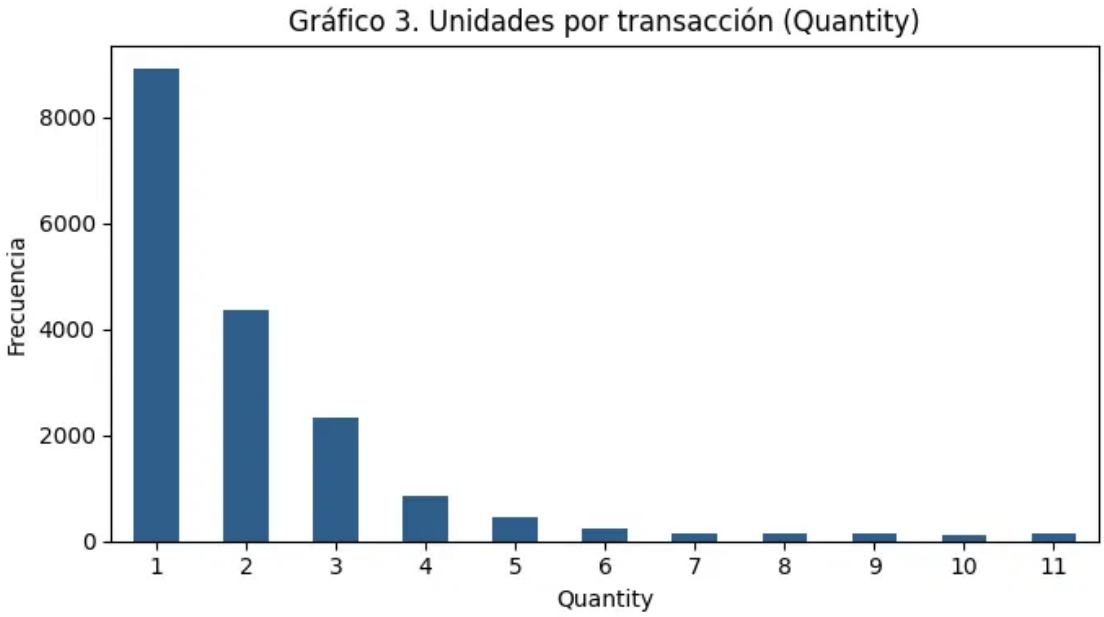
Fuente: Elaboración propia



Fuente: Elaboración propia

En la Tabla 4 y el Grafico 2, Electronics es la categoría dominante, con el 45,54% de las transacciones (8.120). le siguen Office Supplies (25,06%), Furniture (18,37%) y Appliances (11,03%). Electronics y Office Supplies suman el 70,61% del total, y Electronics casi duplica a la segunda categoría y supera cuatro veces a Appliances. El negocio depende, por tanto, de pocas categorías, lo cual es relevante para la pregunta problema porque indica donde se concentra la actividad comercial.

Variables cuantitativas discretas.



Fuente: Elaboración propia

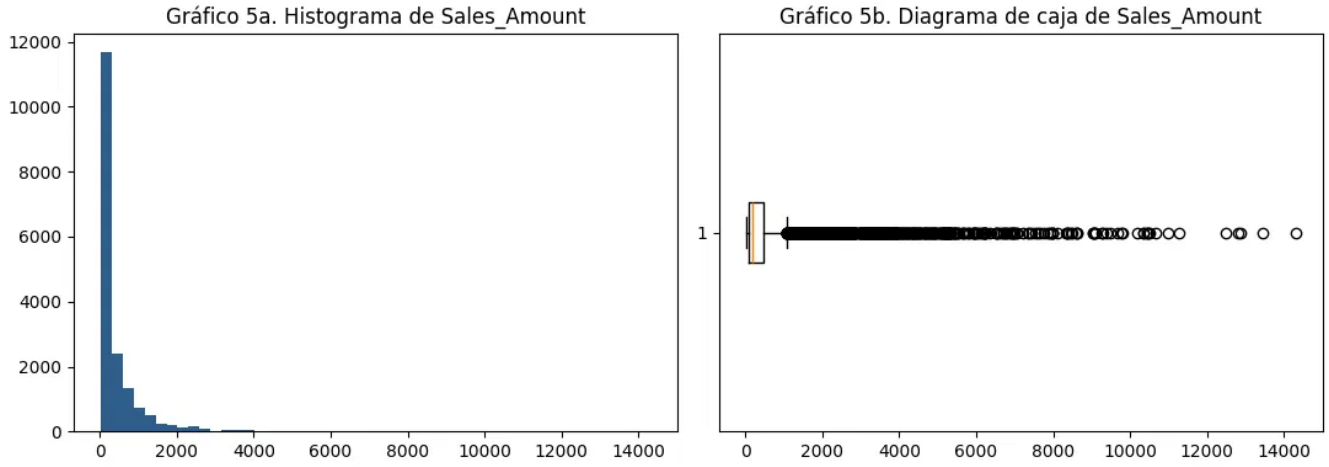
El Grafico 3 Muestra una distribución fuertemente asimétrica hacia la derecha. La mayoría de las compras son pequeñas, el 49,92% de las transacciones (8.901) es de una sola unidad y el 24,37% de dos, de modo que casi tres de cada cuatro (74,29%) no pasan de dos unidades. A partir de ahí la frecuencia cae de forma rápida, con una cola larga de compras de 7 a 11 unidades que suman 687 transacciones (3,85%). Estas compras grandes son las que el criterio del rango intercuartílico clasifica como datos atípicos, y no son errores, ya que las cantidades invalidas ya se eliminaron en la limpieza. Se pueden interpretar como compras por volumen, probablemente asociadas a clientes empresariales.



Fuente: Elaboración propia

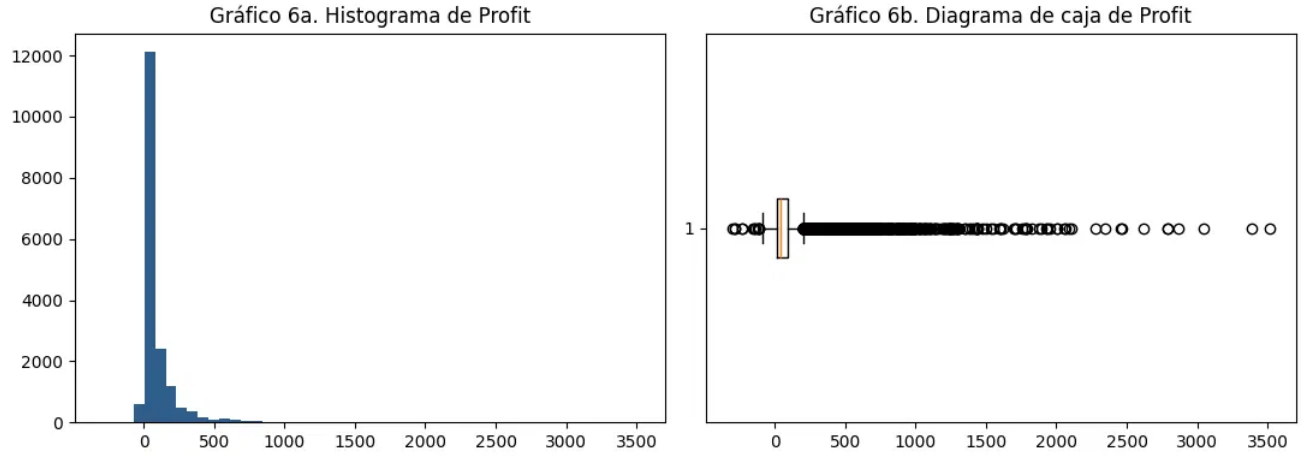
El Grafico 4 presenta una forma distinta. El valor mas frecuente es 0 días, con 6.871 transacciones (38,54%), y con 1 día se llega al 50,19%. Luego hay un segundo grupo de entregas entre 3 y 6 días (39,04%), con picos en 4 y 5 días. Las entregas de 7 días o mas son pocas (725 transacciones, 4,07%) y solo una llega a 10 días. Esta forma sugiere dos grupos de transacciones: unas de entrega inmediata, que posiblemente corresponden a compras en tienda, y otras con despacho de varios días.

Variables cuantitativas continuas.



Fuente: Elaboración propia

El histograma del Grafico 5 tiene un pico bastante alto cerca de cero y una cola larga hacia la derecha que llega hasta 14.303 unidades monetarias. El diagrama de caja muestra una caja angosta (entre 78,52 y 471,61) y una nueve continua de puntos atípicos por encima. Esto nos indica que la gran mayoría de las ventas son de monto bajo y que unas pocas son de valor muy alto. Con el criterio del rango intercuartílico, son atípicas las ventas superiores a 1.061 unidades monetarias, que son 1.768 transacciones (9,9%).



Fuente: Elaboración propia

El Grafico 6 repite el patrón de las ventas, concentración cerca de cero y cola derecha hasta 3.512. La diferencia es que la utilidad toma valores negativos, hasta -299,31, que corresponden a transacciones con perdida y que se ven como puntos a la izquierda de la caja. Los atípicos son 1.850 transacciones (10,4%), tanto por encima de 203,99 como por debajo de -91,24. La forma de la distribución es muy parecida a la de las ventas, lo que anticipa la relación estrecha entre ambas variables que se estudia en el análisis bivariado.

ANALISIS BIVARIADO.

Canal de venta y categoría de producto (dos variables cualitativas).

Tabla 5 Tabla de contingencia: canal de venta por categoría de producto (frecuencias)

Canal de venta	Appliances	Electronics	Furniture	Office Supplies	Total
B2B Portal	239	962	385	525	2.111
Online	871	3.661	1.510	2.073	8.115

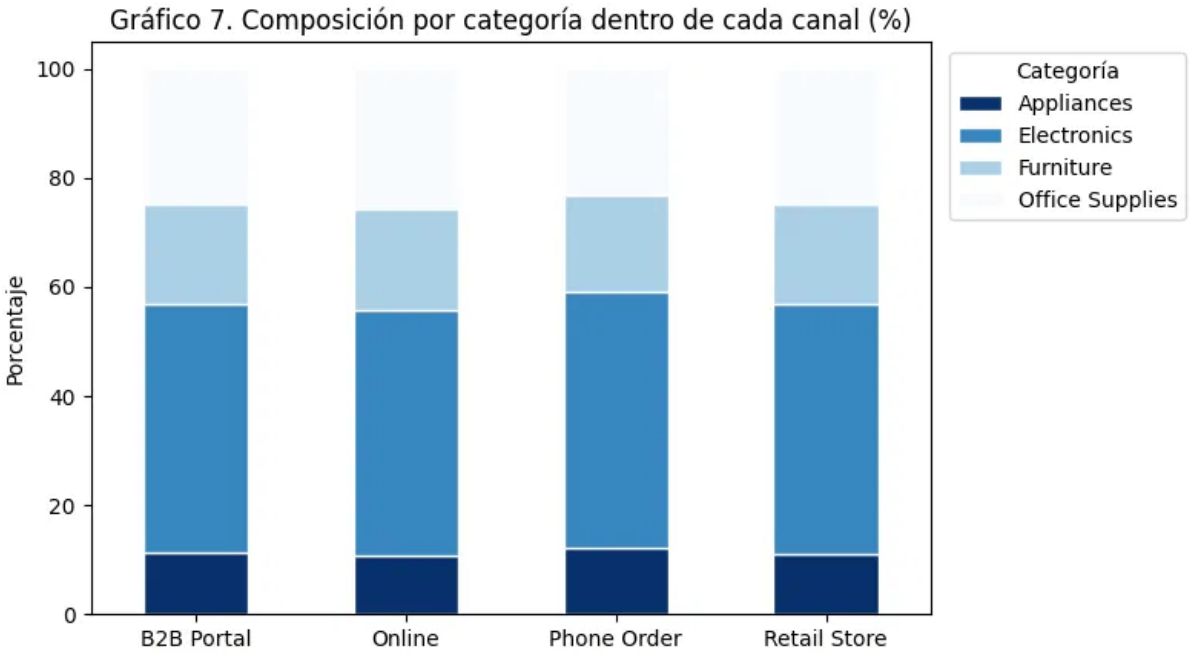
Phone Order	175	675	253	333	1.436
Retail Store	681	2.822	1.127	1.538	6.168
Total	1.966	8.120	3.275	4.469	17.830

Fuente: Elaboración propia

Tabla 6 Distribución porcentual de las categorías dentro de cada canal

Canal de venta	Applicances	Electronics	Furniture	Office Supplies
B2B Portal	11,32	45,57	18,24	24,87
Online	10,73	45,11	18,61	25,55
Phone Order	12,19	47,01	17,62	23,19
Retail Store	11,04	45,75	18,27	24,94

Fuente: Elaboración propia



Fuente: Elaboración propia

La Tabla 5 muestra que la combinación mas frecuente es Online con Electronics (3.661 transacciones), pero eso se explica porque ambos son los grupos mas grandes, no porque haya una afinidad especial entre ellos. La Tabla 6 y el Grafico 7 lo confirman, la mezcla de categorías es casi idéntica en los cuatro canales. Electronics representa entre el 45,11% (Online) y el 47,01% (Phone Order) de las transacciones de cada canal, Office Supplies entre el 23,19% y el 25,55%,

Furniture alrededor del 18% y Appliances entre el 10,73% y el 12,19%. En el grafico, los bloques tienen casi la misma altura en las cuatro columnas.

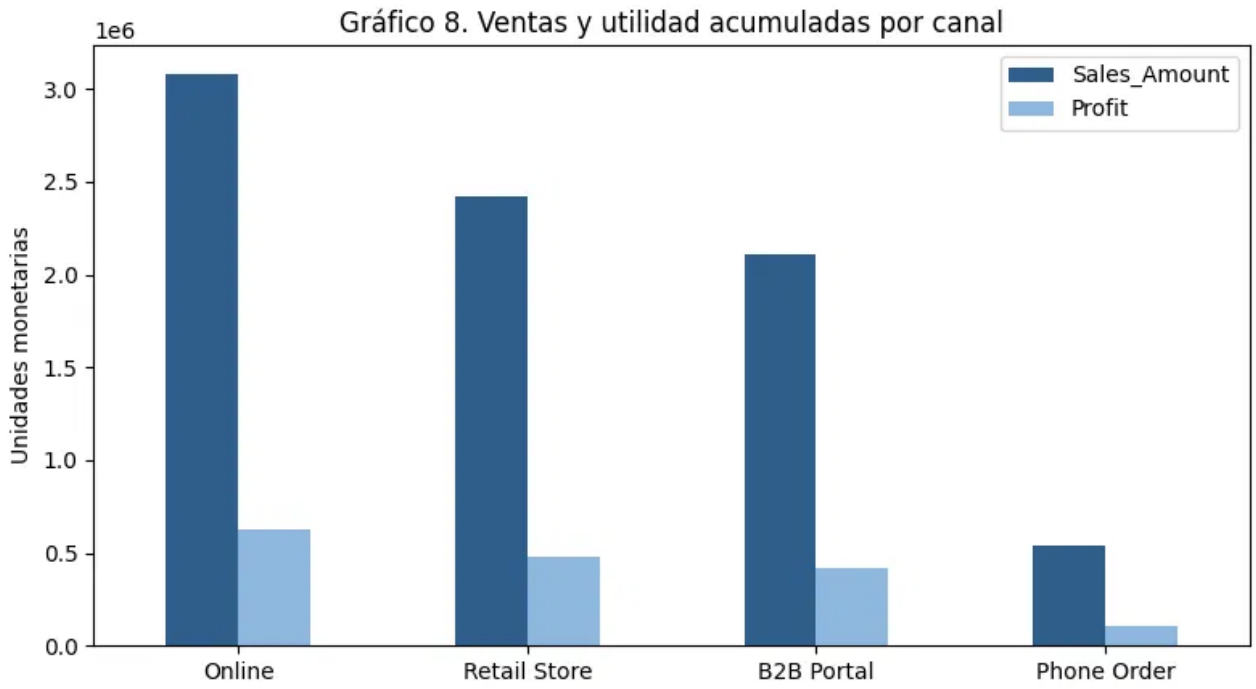
Para verificarlo estadísticamente se aplico la prueba de independencia chi-cuadrado, que dio $\chi^2 = 7{,}20$ con 9 grados de libertad y un p de 0,6168. Como p es mayor que 0,05, entonces no hay evidencia de asociación entre el canal de venta y la categoría del producto, y la V de Cramer (0,0116) está prácticamente en cero. Entonces vemos, que categoría se compra no depende del canal por el que se compra. Esto es importante para la pregunta problema, porque implica que las diferencias entre canales no se explican por los productos que vende cada uno.

Ventas y utilidad por canal.

Tabla 7 Ventas y utilidad acumuladas por canal de venta

Canal de venta	Ventas (unidades monetarias)	Utilidad (unidades monetarias)	Margen (%)	% de las ventas
Online	3.082.494	623.478	20,23	37,82
Retail Store	2.417.960	481.769	19,92	29,66
B2B Portal	2.108.631	416.828	19,77	25,87
Phone Order	541.720	106.737	19,70	6,65

Fuente: Elaboración propia



Fuente: Elaboración propia

La Tabla 7 y el Grafico 8 responden la primera parte de la pregunta problema. Online es el canal que más vende (3,08 millones, el 37,82% del total) y el que mas utilidad deja, seguido de Retail Store, B2B Portal y Phone Order. El margen es prácticamente igual en todos los canales, entre el 19,70% y el 20,23%, por lo que ningún canal es mas rentable en proporción, la diferencia esta en el volumen. Un hallazgo adicional es B2B Portal, que representa solo el 11,84% de las transacciones, pero aporta 25,87% de las ventas, porque su venta promedio por transacción (unas 999 unidades monetarias) es cerca de 2,6 veces la de los demás canales.

Tabla 8 Ventas y utilidad acumuladas por categoria de producto

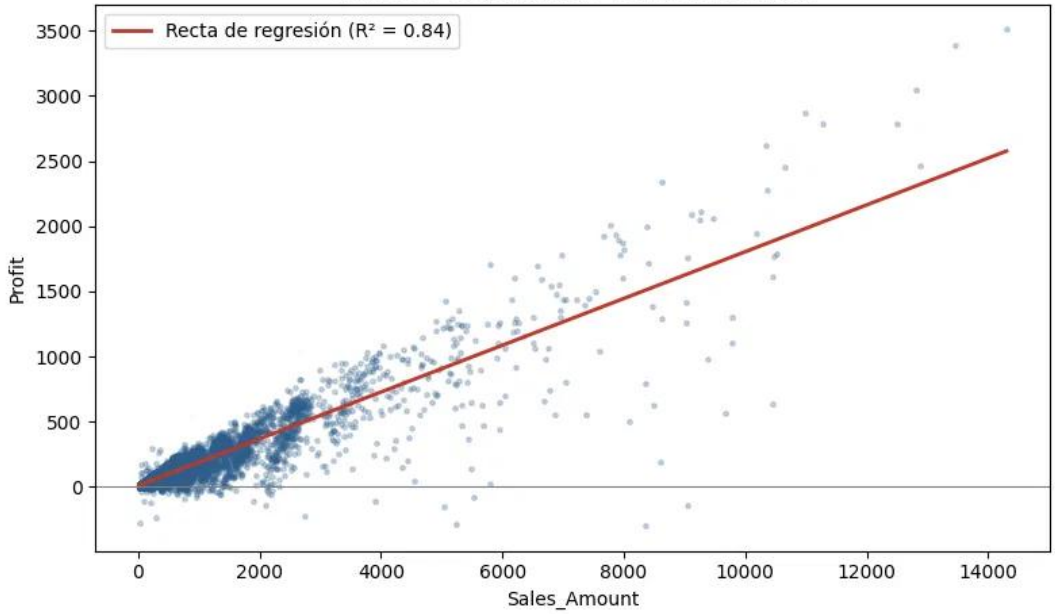
Categoría	Ventas (unidades monetarias)	Utilidad (unidades monetarias)	Margen (%)	% de las ventas
Electronics	4.885.365	944.853	19,34	59,94
Furniture	1.958.979	414.476	21,16	24,03
Office Supplies	729.439	142.361	19,52	8,95
Appliances	577.021	127.122	22,03	7,08

Fuente: Elaboración propia

Por categoría, Electronics concentra casi el 60% de las ventas, con el menor margen (19,34%), mientras que Appliances tiene el mejor margen (22,03%) pero solo el 7,08% de las ventas. Office Supplies representa una cuarta parte de las transacciones, pero apenas el 8,95% de las ventas, porque sus ventas unitarias son menores. Los márgenes son parecidos entre categorías (de 19% a 22%), así que el volumen vuelve a ser lo que determina la utilidad total.

Ventas y utilidad (dos variables cuantitativas).

Gráfico 9. Dispersión de ventas vs. utilidad



Fuente: Elaboración propia

El Grafico 9 muestra una nube de puntos que sube de izquierda a derecha, es decir, una relación lineal positiva y fuerte entre el monto de la venta y la utilidad. El coeficiente de correlación de Pearson es 0,9174 y el de Spearman 0,8868 (ambos con P<0,001), lo que indica que la relación es fuerte tanto en los valores como en el orden de las observaciones, y que no depende solo de unos pocos puntos extremos. La recta de regresión es Profit = 9,28 + 0,1795 x Sales_Amount, con un coeficiente de determinación R^2 = 0,8412. Esto significa que, en promedio, por cada unidad monetaria adicional de venta la utilidad aumenta en promedio 0,18, y que las ventas explican alrededor del 84% de la variación de la utilidad.

MEDIDAS DESCRIPTIVAS.

Tabla 9 Medidas descriptivas de las variables cuantitativas

Medida	Quantity	Delivery_Days	Sales_Amount	Profit
Media	2,13	2,26	457,14	91,35
Mediana	2,00	1,00	168,68	40,17
Moda	1,00	0,00	68,65	10,01
Mínimo	1,00	0,00	16,68	-299,31
Máximo	11,00	10,00	14.303,07	3.512,08
Rango	10,00	10,00	14.286,39	3.811,39
Q1	1,00	0,00	78,52	19,47
Q3	3,00	4,00	471,61	93,28
Rango intercuartílico	2,00	4,00	393,10	73,81

Varianza	3,19	5,39	736.208,31	28.199,39
Desviación estándar	1,78	2,32	858,03	167,93
Coef de variación (%)	83,96	102,63	187,69	183,82
Asimetría	2,62	0,57	5,74	6,63
Curtosis	8,03	-0,97	49,07	72,43
Datos atípicos (n)	687	0	1.768	1.850

Fuente: Elaboración propia

Medidas de tendencia central: En las cuatro variables la media es mayor que la mediana y esta a su vez es mayor o igual que la moda. En la cantidad de unidades, la compra mas frecuente es de 1 unidad, la mitad de las transacciones no pasa de 2, y el promedio es 2,13. En los días de entrega, lo más común es la entrega inmediata (moda de 0 días), la mitad de las entregas se hace en un día o menos, y el promedio sube a 2,26 por las entregas mas demoradas. La diferencia es mucho mas marcada en las variables monetarias, la venta promedio (457,14) es unas 2,7 veces la mediana (168,68), y la utilidad promedio (91,35) es unas 2,3 veces la suya (40,17). Esto significa que la media esta inflada por unas pocas transacciones muy grandes, y que la mediana describe mejor la venta y la utilidad típicas: la mitad de las transacciones vende menos de 169 unidades monetarias y deja menos de 40 de utilidad. La moda de las variables continuas (68,65 y 10,01) tiene poco valor informativo, porque son valores apenas se repiten por azar en una escala continua.

Medidas de dispersión: Los coeficientes de variación son altos en todas las variables, 83,96% en la cantidad, 102,63% en los días de entrega y cerca del 188% y 184% en ventas y utilidad. Cuando la desviación estándar supera a la media, como ocurre en los días de entrega, las ventas y la utilidad, los datos están muy dispersos y la media por si sola no representa bien el conjunto. El rango de las ventas (14.286,39) contrasta con su rango intercuartílico (393,10): el 50% central de las transacciones se concentra entre 78,52 y 471,61, mientras que el resto se extiende en una cola larguísima hasta 14.303,07. En la utilidad ocurre algo parecido, con el 50% central entre 19,47 y 93,28, aunque llega a perdidas de hasta 299,31 y ganancias de hasta 3.512,08.

Medidas de forma: Todas las variables tienen asimetría positiva. En las ventas (5,74) y la utilidad (6,63) es extrema y en la cantidad (2,62) también es fuerte, mientras que en los días de entrega (0,57) es leve. La curtosis confirma que las colas son pesadas en ventas (49,07), utilidad (72,43) y cantidad (8,03), es decir, hay muchos mas valores extremos de los que tendría una distribución normal. En

cambio, los días de entrega tienen curtosis negativa (-0,97), una distribución mas aplanada, sin extremos pronunciados, coherente con que no tenga datos atípicos.

Datos atípicos: Con el criterio del rango intercuartílico, hay 687 transacciones atípicas en cantidad (compras de mas de 6 unidades, el 3,85%), 1768 en ventas (mas de 1.061 unidades monetarias, el 9,9%) y 1.850 en utilidad (el 10,4%, tanto por encima de 203,99 como por debajo de -91,24). Los días de entrega no presentan ninguno. Estos valores no se eliminaron porque no son errores de captura, sino transacciones grandes que forman parte del comportamiento real de la base y que explican buena parte de las ventas totales.

Interpretación en función de la pregunta problema: Las medidas muestran que la actividad comercial tiene dos caras. Por un lado, la transacción típica es pequeña (1 o 2 unidades, unas 169 unidades monetarias de venta y unas 40 de utilidad), con entrega rápida (0 o 1 día). Por otro, existe un grupo reducido de transacciones de montos muy altos, alrededor del 10%, que eleva los promedios y concentra gran parte de los ingresos y de la utilidad. La utilidad promedio equivale a cerca del 20% de la venta promedio (91,35 sobre 457,14), de acuerdo con los márgenes similares que se vieron por canal y categoría. Para responder que canales y categorías generan mas ventas y utilidad, conviene entonces mirar los totales acumulados y no los promedios, y describir el comportamiento típico con la mediana. La alta variabilidad también indica que la utilidad de una transacción individual es poco predecible, en especial en las ventas grandes, y que hay un pequeño grupo de transacciones con perdida que merece seguimiento.

CONCLUSION.

El análisis de las 17.830 transacciones depuradas permite responder la pregunta problema. En cuanto a los canales, Online es el que mas ventas y utilidad genera, seguido de Retail Store, B2B Portal y Phone Order. Por categorías, Electronics domina con el 59,94% de las ventas y el 45,54% de las transacciones. Sin embargo, la rentabilidad es muy similar en todos los casos, el margen ronda el 20% en los cuatro canales (entre 19,70% y 20,23%) y se mueve entre 19,34% y 22,03% según la categoría, de modo que las diferencias en utilidad se explican por el volumen vendido y no por una mayor rentabilidad relativa. La prueba de independencia mostro además que la categoría comprada no depende del canal. Un hallazgo particular es el del B2B Portal, que con el 11,84% de las transacciones aporta el 25,87% de las ventas, gracias a una venta promedio unas 2,6 veces mayor que la de los demás canales.

Respecto a la relación entre el monto vendido y la utilidad, es fuerte y positiva, y la venta explica cerca del 84% de la variación de la utilidad, cada unidad monetaria adicional de venta se asocia, en promedio, con 0,18 unidades de utilidad. Esta relación pierde precisión en ventas altas, donde los puntos se dispersan y aparecen transacciones con perdida.

Las medidas descriptivas muestran que las variables monetarias tienen distribuciones muy asimétricas, con coeficientes de variación cercanos al 185% y cerca del 10% de datos atípicos. La transacción típica es pequeña (mediana de 169 unidades monetarias de ventas y 40 de utilidad, con 1 o 2 unidades y entrega en 0 a 1), pero el 9,92% de las transacciones, las de mayor valor, concentra el 51,22% de las ventas y el 46,45% de la utilidad. Por eso es recomendable describir el comportamiento habitual con la mediana y evaluar el desempeño del negocio con los totales acumulados.

Entre las limitaciones, los datos son sintéticos, por lo que las conclusiones describen el comportamiento de la base y no el de un mercado real, y la moneda de los montos no esta especificada. Además, se trabajó con estadística descriptiva, que nos muestra asociaciones, pero no establece causalidad.

REFERENCIAS.

- Devore, J. L. (2021). *Probabilidad y estadística para ingeniería y ciencias* (9.ª ed.). Cengage Learning.
- Kotler, P., & Keller, K. L. (2016). *Marketing management* (15.ª ed.). Pearson.
- Verhoef, P. C., Kannan, P. K., & Inman, J. J. (2015). From multi-channel retailing to omni-channel retailing: Introduction to the special issue on multi-channel retailing. *Journal of Retailing, 91*(2), 174-181.
- Daniel Sowah. (2026). Retail Sales Dataset. Kaggle. Retail Sales Dataset